

Modelos de Geração Profundos - Modelos de Difusão

Universidade do Minho - Aprendizagem Profunda

Resumo O artigo tem por âmbito dar a conhecer os modelos de difusão de redução de ruído. Primeiramente são explorados e explicados os modelos de geração profunda seguido da abordagem mais profunda no processo de treino e inferência dos modelos de difusão. Este artigo procura também abordar algumas das aplicações principais destes modelos ao longo de várias áreas da ciência e tecnologia assim como expor algumas das suas principais limitações. Por fim serão também discutidos alguns dos principais desafios ao nível da ética e da responsabilidade que devem acompanhar todo o processo de desenvolvimento e uso de modelos de difusão.

Keywords: Modelos de difusão, imagens, inteligência artificial

1 Métodos

1.1 Critérios de Elegibilidade

Na coleção de artigos foram priorizados artigos em inglês ou português relevantes para a área de pesquisa e com um número significativo de referências confiáveis.

1.2 Fontes

Para a coleção de estudos foram utilizadas as seguintes fontes de informação: Google Scholar, arXiv, IEEE Access, GitHub.

1.3 Termos de Pesquisa

Para a procura de artigos recorreremos aos seguintes termos de pesquisa: "Diffusion Models", "Image generation models", "Denoising Diffusion Models", "DDPM Training", "Computer Vision", "Multimodal learning", "DALL-E 2", "U-Net", "AIVA".

1.4 Processo de Recolha de Dados

Foram recolhidos dados dos artigos selecionados sobre definições das áreas abordadas, as suas aplicações e exemplos relevantes.

2 Introdução

Impulsionadas pelo desejo humano de inovar, automatizar e explorar o mundo e sociedade em que nos inserimos, vemos o exponencial crescimento e o surgimento de novas tecnologias. De entre as diversas tecnologias, surge o destaque para as associadas ao ramo da inteligência artificial, tecnologias estas que cada vez mais têm vindo a ser exploradas e abordadas, pelo facto de terem uma correlação para connosco, uma vez que demonstram um carácter relevante relativamente a outras: a capacidade autónoma de aprender e inferir conhecimento. Nesta linha de pensamento, têm vindo a ser desenvolvidos diversos modelos em diferentes áreas, com o intuito de servirem um determinado propósito e efetuarem determinadas atividades, sempre com a capacidade autónoma de aprender e realizarem as suas funções. Além disso, estas tecnologias têm vindo a servir as diversas áreas em que se inserem tanto na medida de automatização como de investigação.

De entre os vários tipos de modelos existentes neste âmbito, podem-se destacar os modelos de geração profundos, que cada vez mais têm vindo a obter especial destaque no suporte de investigações em determinadas áreas. De forma geral, modelos de geração profunda conseguem realizar a difícil tarefa de capturar a complexidade relativamente a dados. Assim, estes admitem qualquer tipo de dados de entrada, gerando através da capacidade de inferência pelo processo de aprendizagem, novas amostras de qualidade agregada e diversificada [1]. Posto isto, no contexto de modelos de geração profundos, existem diversos substratos para funções especializadas e para áreas específicas. Um exemplo destes, são os modelos de difusão que têm um papel fundamental neste âmbito, sendo caracterizados pela capacidade autónoma e independente de dados, de produzir imagens partindo de ruído. Diversas aplicações têm sido implementadas no contexto de modelos de difusão em diferentes áreas, quer em investigação quer aplicacional, sendo cada vez mais um dos modelos mais promissores no âmbito dos modelos de geração profundos.

3 Definição de Modelos de Geração Profundos

A área da inteligência artificial engloba outros dois ramos na mesma vertente, destacando-se a **aprendizagem máquina** e a **aprendizagem profunda**, no qual em qualquer um a capacidade de aprendizagem deve-se à presença de duas fases cruciais: fase de treino e fase de testes. Na fase de treino destaca-se o âmbito de aprender e adequar quaisquer futuras inferências dadas outras passadas, enquanto a fase de testes revê a qualidade da fase anterior [1]. Podemos então definir estes três setores das tecnologias inteligentes da seguinte maneira (figura 1):

- **Inteligência Artificial:** Consiste em todo o tipo de sistemas que conseguem realizar tarefas de forma autónoma [1];

- **Aprendizagem Máquina:** Consiste em todo o tipo de algoritmos de aprendizagem que permite um dado sistema agir de forma autónoma e com capacidade de aprendizagem, sem terem de ser declaradas as regras de ação [1]. O processo de aprendizagem pode ser um dos seguintes:
 - **Supervisionada:** O processo de aprendizagem é revisto e retificado por um tutor, com o intuito de melhorar o mesmo;
 - **Não supervisionada:** O processo de aprendizagem não é interferido por nenhum tutor, cabendo ao sistema inferir sobre os dados;
 - **Por reforço:** O processo de aprendizagem passa pela noção de "recompensa-penalização", mediante as ações tomadas pelo sistema;
- **Aprendizagem Profunda:** Consiste em todo o tipo de sistemas que se inserem no âmbito de aprendizagem máquina, mas cujos algoritmos de aprendizagem são redes neurais artificiais [1];




Figura 1. Setores da Inteligência Artificial [20]

De salientar que este último setor tem vindo a ser cada vez mais enaltecido, pela popularidade dada às famosas redes neuronais artificiais, cujo funcionamento assemelha-se à de uma rede neural humana, com capacidade de inferência relativamente às ações efetuadas sobre os dados, aprendendo através das mesmas. Assim, nesta vertente, os modelos generativos inserem-se no contexto da aprendizagem profunda, tendo como base de funcionamento as redes neuronais artificiais. Estes modelos têm como paradigma de aprendizagem o não supervisionado, destacando-se pela vertente de aprender qualquer tipo de distribuição de dados. Assim, qualquer modelo que se insira neste tipo, requer a presença de dados de forma a serem feitas as diversas inferências sobre estes, de modo

a obter a melhor distribuição dos mesmos [2]. Com isto, na fase de treino dum qualquer modelo deste tipo, são requeridos grandes quantidade de dados, com o intuito de aprender a verdadeira distribuição dos mesmos e posteriormente na fase de testes ser capaz de gerar novas amostras com pequenas variações.

Este tipo de modelos agregam outros modelos mais específicos, do qual se inserem em diversas áreas como no processamento de linguagem natural, áudio e música, medicina e biologia e também nas finanças.

4 Definição de Modelos de Difusão

Os modelos de difusão representam uma das arquiteturas de inteligência artificial mais promissoras e emergentes na atualidade. Estes modelos têm ganho cada vez mais relevância na criação de conteúdo digital, não apenas no campo da geração de imagens, mas também na produção de músicas, vídeos, proteínas e até identificação de tumores ou melanomas em imagens de ressonância magnética e imagens da pele de pacientes, respetivamente[8]. Ao contrário de outras abordagens de geração de conteúdo como GANs[10] ou VAEs[11], os modelos de difusão utilizam uma abordagem iterativa, criando novas informações a partir de ruído. Isso faz com que os resultados gerados pelos modelos de difusão tenham geralmente uma qualidade superior[9]. Além disso, a utilização de modelos de difusão tem-se mostrado muito eficiente em diversas áreas, permitindo avanços significativos em muitos campos, como medicina, biologia, entretenimento e design.

4.1 Funcionamento

Assim como as formas de inteligência artificial com base em redes neuronais têm de seguir um processo de treino antes de poderem ser utilizadas, o mesmo acontece com modelos de difusão. Uma vez que estes modelos podem ser utilizados em diversos contextos e seguir diversos processos de treino, será apenas explicado de forma simples o treino destes modelos no contexto de geração de imagens, dado que esta é uma das áreas em que estes são mais utilizados e produzem os resultados mais impressionantes. Como tal, qualquer referência a modelos de difusão neste capítulo referem-se na sua larga maioria a modelos probabilísticos de difusão de redução de ruído (DDPMs)[2] para geração de imagens condicionadas numa descrição textual.

4.1.1 Treino

A primeira etapa de qualquer processo de treino é a recolha de uma quantidade significativa de dados, neste caso de imagens. Antes destas imagens serem usadas para treinar o modelo, é aplicada uma distribuição gaussiana de ruído n vezes para diminuir a "qualidade" da imagem. Depois o objetivo do modelo é prever a distribuição de ruído que foi adicionado à imagem (com a ajuda da descrição da imagem) para que este lhe possa ser retirado e assim obter a imagem inicial

(figura 2). Quantas mais vezes for aplicado ruído mais difícil será voltar à imagem original obrigando o modelo a guiar-se pela descrição. Em certos casos a qualidade do modelo é avaliada tendo em conta o quanto a imagem se relaciona com a descrição, permitindo obter ainda melhores resultados[2].




Figura 2. Processo de treino e inferência de modelos de difusão[15]

4.1.2 Inferência

Para criar imagens novas no processo de inferência, é fornecido ao modelo apenas uma descrição sob a forma de texto e ruído aleatório. Assim, sem nenhuma imagem que possa ter como base, o modelo retira o ruído baseando-se no texto fornecido. Este processo é realizado iterativamente n vezes até se obter uma imagem limpa que espelhe a sua descrição[2].

5 Aplicabilidade e Viabilidade

Os modelos de difusão generativos são modelos com uma grande flexibilidade e capacidade de gerar o mais variado tipo de conteúdo, por essa razão têm sido nos últimos anos aplicados às mais diversas áreas da ciência[8] onde têm apresentado resultados significativos, acelerando assim o ritmo de progresso em áreas como:

5.1 Visão por Computador

Esta área refere-se ao processamento, análise e geração de imagens ou vídeos. Os modelos de difusão são extensivamente utilizados em visão por computador dado que uma das suas principais aplicações é a geração de imagens. No entanto, esta área pode ser dividida em várias categorias no que toca à aplicação destes modelos.

Super Resolução: É o processo de reconstruir imagens de alta resolução através das imagens de baixa resolução fornecidas ao modelo. O modelo gera imagens cada vez mais nítidas iterativamente até se obter a imagem final[3][4].

Inpainting: Processo que reconstrói secções da imagem em falta ou zonas além das bordas, sendo esta uma outra forma de aumentar o tamanho da imagem mas gerando novo conteúdo que não faz parte da imagem original[8].

Segmentação de Imagens: É um processo que identifica certas zonas de uma imagem contendo alguma entidade que o modelo foi treinado para reconhecer. É muito utilizado em ramos ligados à medicina uma vez que permite identificar zonas de uma imagem onde se encontrem anomalias, como por exemplo a identificação de tumores em ressonâncias[6]. Podem ser encontrados artigos e respetivas implementações relativos a modelos de difusão na área da medicina em [GitHub](#).

Tradução de Imagem para Imagem: Refere-se ao processo de receber uma imagem e aplicar algum tipo de modificação a nível estilístico ou estrutural para obter uma nova imagem baseada na anterior[14].

5.2 Aprendizagem Multi-Modal

Na procura por desenvolver inteligência artificial cada vez inteligente e capaz de interagir com o mundo tal como os humanos, é necessário que estas sejam capazes de processar informação digital nas suas variadas formas, como áudio, texto, imagens e vídeos. Com este objetivo são criados os modelos multi-modais capazes de interagir com vários tipos de dados desenvolvendo capacidades tais como:

Texto para Imagem: Modelos treinados com este objetivo têm a capacidade de receber uma descrição de uma imagem sob a forma de texto e gerar uma imagem que se aproxime da descrição fornecida[2].

Texto para Áudio: Tal como no exemplo anterior esta aplicação de modelos de difusão baseia-se na criação de áudio dada uma descrição em forma textual. Pode ser utilizada para gerar vozes artificiais que leem o texto fornecido ou para gerar música com base na sua descrição [5][13].

Modelação de Grafos Moleculares: A criação de moléculas e novos compostos químicos é muitas vezes um processo lento e complexo que pode ser acelerado com a introdução de modelos de difusão capazes de gerar novos compostos moleculares, acelerando áreas como por exemplo a criação de vacinas[8].

6 Casos de Estudo de Modelos de Difusão

Dadas as diferentes aplicações que os modelos de difusão apresentam, é notório a presença de várias soluções já desenvolvidas por entidades de renome quer para uso empresarial, de investigação e/ou suporte de serviços. Assim, existem na literatura científica diversos artigos relativos a estas soluções, tendo sempre como foco os modelos de difusão, variando alguns aspetos mais profundos que dizem respeito quer ao funcionamento quer à implementação dos mesmos. Estas soluções inserem-se numa dada área, servindo de apoio à mesma no que concerne quer à resolução de atividades, quer ao âmbito de potenciais investigações, havendo uma extensa diversidade das mesmas.

6.1 DALL-E 2

O [DALL-E 2](#) [7] é um sistema de inteligência artificial concebido pela conhecida OpenAI tendo sido desenvolvido no seguimento do DALL-E, um sistema que pode gerar imagens a partir de texto, elevando a fasquia desta implementação trazendo maior resolução, maior compreensão e também novos recursos. Inserindo-se no contexto de geração de imagens através de uma dada descrição, o DALL-E 2 tem a capacidade de analisar descrições de texto simples e transformá-las em imagens fotorrealistas que nunca existiram antes, tendo também a destreza de editar e aprimorar fotos de forma realista. Além disso, utiliza a técnica já mencionada e descrita, o "inpainting".

O DALL-E 2 tem como base de modelo de aprendizagem uma rede neural, cujo a mesma foi treinada através do fornecimento de milhares e diferentes imagens e as suas correspondentes descrições de texto. Assim, a solução desenvolvida insere-se no âmbito da aprendizagem profunda, tendo a capacidade de não só compreender objetos individuais, mas também as relações e ações entre os objetos, isto é, tem a capacidade de gerar imagens cujo conteúdo apresenta alguma relação e/ou ação entre várias entidades distintas descritas através do texto fornecido.

Como qualquer tecnologia, existem vantagens de especial interesse relativos ao DALL-E 2, bem como desvantagens. De entre as vantagens, podemos destacar as seguintes:

- **Expressividade:** Permite que o utilizador se expresse visualmente de maneiras que não pudesse anteriormente;
- **Criatividade:** Tem a capacidade de inferir acerca de situações às quais não aprendeu, originando um processo criativo do que melhor poderá ser visualmente a descrição textual que lhe é "desconhecida";
- **Qualidade:** Uma vez que é uma otimização do DALL-E, consegue gerar imagens com maior resolução e mais realistas;

Relativamente às desvantagens demonstradas, estas dizem respeito maioritariamente ao processo de treino, algo comum em modelos de aprendizagem profunda, mas existem outras, tais como:

- **Interpretação:** Pode gerar imagens que não vão de encontro à descrição textual prestada. Isto deve-se ao processo de treino, no qual caso tenha aprendido a identificar um dado objeto/entidade com a descrição errada, irá futuramente gerar imagens erradas para a mesma descrição;
- **Tempo:** O tempo de geração associado às imagens descritas textualmente é um fator a ter em conta, variando consoante a complexidade da descrição;

6.2 U-Net

O U-Net [17] [18] é um modelo de difusão que utiliza um tipo de rede neural conhecido como rede neural convolucional, sendo inicialmente desenvolvido no âmbito da medicina relativamente à segmentação de imagens biomédicas. O modelo aprende a segmentação de uma dada imagem através de uma configuração de ponta a ponta, no qual lhe é fornecida uma imagem que produz como resultado um mapa de segmentação. O processo de segmentação de imagens do U-Net funciona a partir da classificação de cada pixel da imagem de entrada para que no resultado produzido este tenha o mesmo valor, permitindo localizar e distinguir fronteiras com precisão.

No que concerne a aspetos relevantes na área para o qual foi inicialmente desenvolvido, o U-Net destaca-se com extrema elegância nas várias tarefas de segmentação de imagens médicas, como na segmentação de células e segmentação de tumores cerebrais. Além disso, o U-Net não está só limitado para a área da medicina, tendo a sua implementação sido extendida e adaptada de forma a poder ser aplicado a outras tarefas de segmentação noutras áreas, tais como da construção civil, através da segmentação de edifícios, e aeroespacial na segmentação de estradas em imagens de satélite. No âmbito geral, o U-Net permite também a segmentação de objetos de várias formas e tamanhos com alta precisão, trazendo vantagens mas também desvantagens. Das vantagens relativas ao U-Net, podemos destacar as seguintes:

- **Dados:** O U-Net não necessita de grandes quantidades de dados para poder ser treinado, limitação esta presente no ramo da medicina;
- **Complexidade:** Relativamente a outros modelos de segmentação de imagens, o U-Net apresenta menos complexidade no que concerne ao funcionamento do mesmo;

Relativamente às desvantagens, podemos destacar as seguintes:

- **Tarefas:** Uma vez que foi concebido exclusivamente para a segmentação de imagens, este não possui versatilidade no que compete ao desempenho de outras funções;
- **Dimensão:** O U-Net é mais apto a obter melhores resultados para imagens 2D do que 3D;

6.3 AIVA

O **AIVA**, (Artificial Intelligence Virtual Artist) [19], é um sistema de inteligência artificial concebido pela AIVA Technologies, no âmbito de composição musical, sendo capaz de gerar músicas personalizadas em diferentes estilos e géneros pretendidos através de modelos de difusão. Este sistema utiliza aprendizagem profunda de forma a analisar e aprender com as grandes quantidades de dados musicais que lhe foram fornecidos na fase de treino, permitindo desenvolver peças musicais inéditas. Assim, o AIVA, permite a criação de músicas personalizadas de acordo com preferências e diversos parâmetros definidos pelo utilizador, tais como o ritmo, género, composição e instrumentos. Além disso, permite que um utilizador não familiarizado com a composição e/ou treino musical crie uma música através da especificação dos parâmetros.

Assim, o conteúdo produzido pelo AIVA tem diversas aplicabilidades que se inserem em áreas distintas tais como na realização de trilhas sonoras de filmes e jogos eletrónicos. Através da extensa recolha de dados musicais que se inserem em diferentes géneros e estilos para a fase de treino, o AIVA tem a capacidade de agregar estilos musicais tais como clássico, eletrónico, jazz, entre outros. Outra capacidade deste sistema é a geração de música em tempo real, apelativo para apresentações e eventos ao vivo, além de que possui uma interface interativa e fácil de compreender. No que concerne a vantagens, podemos destacar as seguintes:

- **Produtividade:** Com a capacidade de gerar contexto musical, o AIVA consegue aumentar a produtividade de diversas indústrias na área da música;
- **Expressividade:** Qualquer pessoa, mesmo sem conhecimento musical, consegue expressar-se e criar música, que de outras maneiras lhe seriam mais difíceis;

No que diz respeito às desvantagens relativas a este sistema, podemos enaltecer as seguintes:

- **Dados:** Tal como a maioria dos sistemas de aprendizagem profunda, o AIVA depende de grandes quantidades de dados;
- **Mitigação:** Com a capacidade de criar composições musicais, várias indústrias ligadas à produção de música podem ser mitigadas na medida que tais criações são rapidamente geradas através do AIVA;

7 Ética, Responsabilidade e Limitações

A ética é crucial quando se trata de usar modelos de difusão. Os dados usados para treinar esses modelos devem ser recolhidos de forma ética e legal, respeitando não só as políticas de privacidade mas também tendo em consideração os direitos de autor. Além disso, é importante considerar o impacto potencial que o uso desses modelos pode ter nas pessoas e comunidades afetadas. Por exemplo,

se um modelo é usado para melhorar a qualidade de imagens médicas, é fundamental garantir que as decisões tomadas com base nessas imagens sejam precisas e confiáveis, pois isso pode ter consequências significativas na saúde das pessoas envolvidas. Outro exemplo é o seu uso de forma maliciosa para criar imagens falsas que espalhem desinformação sobre alguma pessoa ou entidade, pois dado o volume de dados usados no processo de treino não é difícil para estes modelos produzir imagens de figuras públicas[2].

Além da ética, a responsabilidade é outra questão importante a ser considerada ao usar modelos de difusão. Como estes modelos podem ser usados para tomar decisões importantes, é necessário garantir que sejam usados de maneira responsável e justa. Isso significa garantir que estes modelos sejam justos, precisos e confiáveis. Além disso, é necessário que os dados usados para os treinar sejam representativos da população que são destinados a servir. Tais falhas representativas nos *datasets* levam a falhas representativas nos conteúdos gerados, criando modelos tendenciosos.

Por fim, é importante reconhecer as limitações dos modelos de difusão. Embora seja uma técnica poderosa de geração e melhoramento de imagens e sinais, estes modelos têm as suas limitações. Por exemplo, podem ter dificuldade em lidar com dados de baixa qualidade ou com dados incompletos. Além disso, os resultados produzidos por estes modelos podem depender significativamente dos parâmetros escolhidos e dos dados usados para treinar o modelo, o que pode levar a tendências que por exemplo, desfavorecem minorias étnicas [22].

Além destas limitações temos também as limitações que estão associadas a todos os tipos de modelos generativos, como a imprevisibilidade do conteúdo gerado assim como a falta de qualidade em certos aspetos como por exemplo a dificuldade em gerar mãos humanas[21] no caso dos modelos DDPM de geração de imagens.

Assim, é fundamental garantir que estes modelos sejam usados de maneira justa e responsável, e que as suas limitações sejam reconhecidas e levadas em consideração ao tomar decisões com base nos resultados produzidos por estes modelos.

8 Conclusão

Pode-se sumarizar que a inteligência artificial tem hoje em dia um papel imergente na sociedade estando os modelos de difusão na linha da frente em algumas áreas como a criação de conteúdo digital sintético de grande qualidade e na segmentação de imagens a nível médico.

Assim com o constante desenvolvimento da tecnologia e a crescente demanda por conteúdo digital inovador, espera-se que os modelos de difusão se tornem ainda mais relevantes e impactantes no futuro próximo, possibilitando a criação de novas formas de arte, entretenimento e ciência.

Siglas e Acrónimos

- **AI** - *Artificial Intelligence*
- **ML** - *Machine Learning*
- **DL** - *Deep Learning*
- **GAN** - *Generative Adversarial Network*
- **VAE** - *Variational Autoencoder*
- **DDPM** - *Denoising Diffusion Probabilistic Models*
- **AIVA** - *Artificial Intelligence Virtual Artist*

Referências

1. Hu, Z., Yang, Z., Salakhutdinov, R., Xing, E. P. (2017). [On Unifying Deep Generative Models](#). ArXiv (Cornell University).
2. Ho, J. C., Jain, A., Abbeel, P. (2020). [Denoising Diffusion Probabilistic Models](#). ArXiv (Cornell University).
3. Li, H., Yang, Y., Chang, M., Chen, S., Feng, H., Xu, Z., Li, Q., Chen, Y. (2022). [SRDiff: Single image super-resolution with diffusion probabilistic models](#).
4. Shi, W., Caballero, J., Huszar, F., Totz, J., Aitken, A., Bishop, R., Rueckert, D., Wang, Z. (2016). [Real-Time Single Image and Video Super-Resolution Using an Efficient Sub-Pixel Convolutional Neural Network](#). Computer Vision and Pattern Recognition.
5. Hawthorne, C., Simon, I., Roberts, A., Zeghidour, N., Gardner, J., Manilow, E., Engel, J. (2022). [Multi-instrument Music Synthesis with Spectrogram Diffusion](#). ArXiv (Cornell University).
6. Kazerouni, A., Aghdam, E., Heidari, M., Azad, R., Hacihaliloglu, I., Merhof, D. (n.d.). [DIFFUSION MODELS FOR MEDICAL IMAGE ANALYSIS: A COMPREHENSIVE SURVEY](#).
7. Ramesh, A., Dhariwal, P., Nichol, A., Chu, C., Openai, M. (n.d.). [Hierarchical Text-Conditional Image Generation with CLIP Latents](#).
8. Yang, L., Zhang, Z., Hong, S., Zhang, W., Cui, B. (n.d.). [DIFFUSION MODELS: A COMPREHENSIVE SURVEY OF METHODS AND APPLICATIONS](#).
9. Dhariwal, P., Nichol, A. (2021). [Diffusion Models Beat GANs on Image Synthesis](#). ArXiv (Cornell University).
10. Ian, G., Jean, P., Mehdi M., Bing X., David W., Sherjil O., Aaron C., Yoshua B. (2020). [Generative adversarial networks](#). Communications of the ACM.
11. Diederik K., Max W. (2013). [Auto-Encoding Variational Bayes](#).
12. George P., Eric N., Danilo R., Shakir M., Balaji L. (2021). [Normalizing flows for probabilistic modeling and inference](#).
13. Zhifeng K., Wei P., Jiaji H., Kexin Z., Bryan C. (2021). [Diffwave: A versatile diffusion model for audio synthesis](#).
14. Omri A., Dani L., Ohad F. (2022). [Blended diffusion for text-driven editing of natural images](#). Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition.
15. Lemerrier J., Richter J., Welker S., Gerkmann, T. (n.d.). [Denoising Diffusion-Based Generative Modeling: Foundations and Applications](#).
16. Jonathan H., Ajay J., Pieter A. (2020). [Denoising diffusion probabilistic models](#). Advances in Neural Information Processing Systems.

17. Yin, X.-X., Sun, L., Fu, Y., Lu, R., Zhang, Y. (2022). [U-Net-Based Medical Image Segmentation](#). Journal of Healthcare Engineering, 2022, 4189781.
18. Siddique, N., Paheding, S., Elkin, C. P., Devabhaktuni, V. (2021). [U-Net and Its Variants for Medical Image Segmentation: A Review of Theory and Applications](#). IEEE Access, 9, 82031–82057.
19. Rodrigo O. (n.a). [INTELIGÊNCIA ARTIFICIAL COMO FERRAMENTA DE AUXÍLIO NA EDUCAÇÃO MUSICAL](#).
20. Wang, Tianming, Zhu Chen, Quanliang Shang, Cong Ma, Xiangyu Chen, and Enhua Xiao. 2021. [A Promising and Challenging Approach: Radiologists' Perspective on Deep Learning and Artificial Intelligence for Fighting COVID-19](#). Diagnostics 11, no. 10: 1924.
21. Dixit, P. (n.d.). [AI Image Generators Keep Messing Up Hands. Here's Why](#). Buzz-Feed News.
22. Scale AI. (n.d.). [Diffusion Models: A Practical Guide](#). ScaleAI.